.UBAfiuba
FACULTAD DE INGENIERÍA

Ciencia de Datos
(TA047) Curso Rodríguez - Villanueva

Trabajo Práctico 1

14 de octubre de 2026

Thiago Reller
111067

Sofía Encina
111891

Ignacio Politti
112034

Francisco Serrano
111813

Salvador Perez Mendoza
110198

Índice

1. EJERCICIO 1: Análisis exploratorio de datos y agrupamiento **4**
1.1. Introducción . . . 4
1.1.1. Objetivo . . . 4
1.2. Dataset . . . 4
1.2.1. Datasets de Rebrickable utilizados y justificación . . . 4
1.2.2. Descripción del dataset analítico construido . . . 5
1.2.3. Variables más relevantes . . . 5
1.2.4. Hipótesis iniciales y supuestos de trabajo . . . 5
1.2.5. Nuevos features generados . . . 6
1.2.6. Valores atípicos . . . 6
1.2.7. Datos faltantes: proporción y tratamiento . . . 6
1.2.8. Exploración inicial de variables . . . 7
1.3. Preguntas de investigación . . . 7
1.3.1. Pregunta 1: ¿Los sets que incluyen otros sets tienden a tener más piezas que aquellos que no incluyen sub-sets? . . . 7
1.3.2. Pregunta 2: ¿Existen temas que reutilicen una mayor proporción de tipos de piezas entre sus sets que otros? . . . 8
1.3.3. Pregunta 3: ¿Qué porcentaje de minifiguras son reutilizadas en múltiples sets frente a aquellas que son exclusivas? . . . 10
1.3.4. Pregunta 4: ¿Los sets con más piezas usan también más colores distintos? ¿Esa relación cambia según el tema y la época? . . . 11
1.4. Agrupamiento . . . 14
1.4.1. Objetivo y unidad de análisis . . . 14
1.4.2. Variables utilizadas y justificación . . . 14
1.4.3. Transformaciones aplicadas . . . 14
1.4.4. Tendencia al clustering . . . 15
1.4.5. Estimación de la cantidad de grupos . . . 15
1.4.6. Evaluación de la calidad de los grupos . . . 16
1.4.7. Visualización de los grupos . . . 16
1.4.8. Caracterización de los grupos . . . 17
1.4.9. Limitaciones . . . 18
1.5. Conclusiones . . . 18
1.5.1. Principales hallazgos del análisis . . . 18

2. Ejercicio 2: Modelos de regresión **19**
2.1. Introducción . . . 19
2.1.1. Objetivo . . . 19
2.2. Dataset . . . 19
2.2.1. Descripción del dataset . . . 19
2.2.2. Variables relevantes . . . 19
2.2.3. Datos faltantes: proporción y tratamiento . . . 19

2.2.4. Nuevas variables generadas 20
2.2.5. Variables eliminadas 20
2.2.6. Valores atípicos 20
2.2.7. Preparación para el modelado 21
2.2.8. Exploración de variables 21
2.3. Modelos entrenados 22
2.3.1. Regresión lineal múltiple 22
2.3.2. Modelo a elección: Random Forest 23
2.4. Cuadro comparativo de resultados en prueba 24
2.5. Elección del modelo 25

3. EJERCICIO 3: Competencia de Machine Learning 26
3.1. Preprocesamiento del Dataset 26
3.1.1. Preprocesamiento y Feature Engineering 26
3.2. Modelos Entrenados 26
3.2.1. Modelos Individuales: Árbol de Decisión, Random Forest y XGBoost 26
3.2.2. Ensambles Híbridos 31
3.3. Cuadro Comparativo de Resultados 32
3.3.1. Tabla de Métricas en Validación / Test 32
3.3.2. Análisis de Desempeño y Preguntas de Discusión 32
3.3.3. Entregas Realizadas en Kaggle 33

1. EJERCICIO 1: Análisis exploratorio de datos y agrupamiento

1.1. Introducción

En este ejercicio se nos brindan distintos data sets de Rebrickable, que contienen informacion sobre elementos del mundo de LEGO. Con estos se nos pide desarrollar este ejercicio utilizando obligatoriamente a **sets**, **themes**, **inventories** e **inventory_parts**, además de elegir otros 2 data sets de los disponibles.

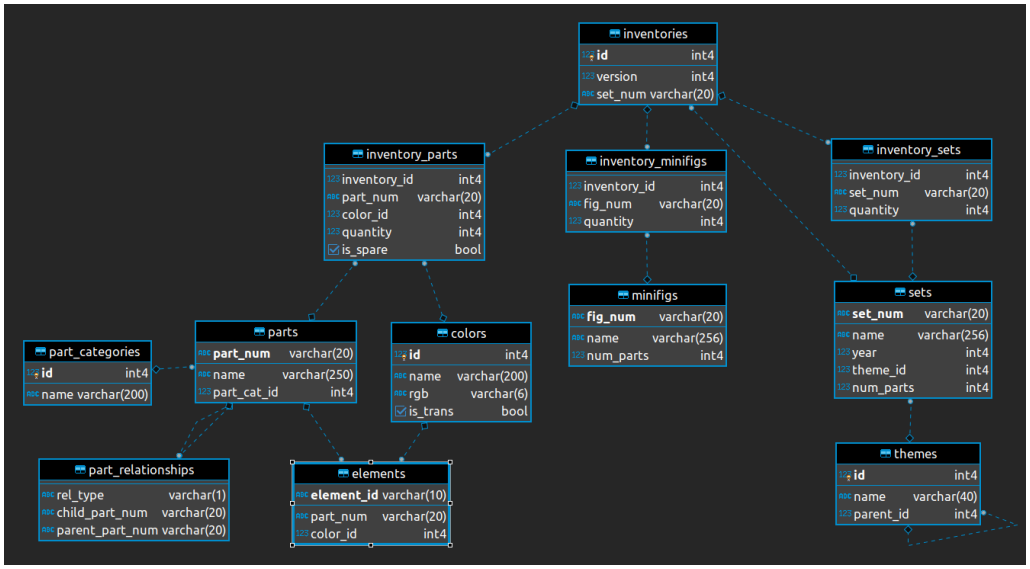


Figura 1: Datasets de LEGO disponibles en la página.

1.1.1. Objetivo

El objetivo de este ejercicio es integrar distintas fuentes de datos de Rebrickable para construir un dataset analítico que permita estudiar características y relaciones de los sets LEGO. A partir de este dataset se busca responder preguntas de investigación utilizando técnicas de análisis exploratorio de datos y evaluar la existencia de agrupamientos naturales utilizando el algoritmo K-Means y métricas de calidad como Silhouette.

1.2. Dataset

1.2.1. Datasets de Rebrickable utilizados y justificación

Para el desarrollo del análisis exploratorio se integraron los datasets de Rebrickable que se detallan a continuación. Cuatro de ellos obligatorios por consigna:

- **sets.csv**
- **themes.csv**
- **inventories.csv**
- **inventory_parts.csv**

Y los siguientes fueron agregados para el desarrollo del ejercicio:

- **inventory_sets.csv:** Permite vincular parts, minifigs y sets pertenecientes a un mismo invetory.
- **inventory_minifigs.csv y minifigs.csv:** Permiten identificar la presencia y frecuencia de aparición de minifiguras dentro de los sets.
- **colors.csv:** Atributos de color, incluyendo la cualidad de transparencia (`is_trans`).
- **parts.csv:** Piezas con sus categorías (`part_cat_id`).

1.2.2. Descripción del dataset analítico construido

A partir del dataset analítico construido se derivan cuatro tablas o vistas analíticas orientadas a cada pregunta de investigación:

1. **Vista de Sets y Sub-sets [Pregunta 1]:** Dataset compuesto por registros de sets cuyos inventarios documentan al menos una pieza.
2. **Vista de Reutilización por Tema [Pregunta 2]:** Agregación por temática que sintetiza la cantidad total de piezas y tipos de piezas únicas por tema.
3. **Vista de Exclusividad de Minifiguras [Pregunta 3]:** Dataset que contabiliza la cantidad de sets únicos en los que aparece cada figura.
4. **Vista de Diversidad y Paleta Cromática [Pregunta 4]:** Dataset que sintetiza variables cuantitativas de tamaño, variedad de tipos de piezas, recuento de colores únicos y porcentaje de piezas transparentes.
5. **Vista de Composición por Set [Agrupamiento]**: Dataset con una fila por set y variables relativas de tamaño, repetición de piezas, variedad cromática,variedad de categorías y proporción de piezas transparentes construido sobre los mismos criterios que la Vista de Diversidad y Paleta Cromática.

1.2.3. Variables más relevantes

- `num_parts_total` (Cuantitativa entera): Suma de piezas del set y piezas aportadas por sus sub-sets.
- `tiene_subsets` (Cualitativa): Indica si el set principal contiene sub-modelos independientes.
- `repetition_ratio` (Cuantitativa continua): Cociente total_parts/unique_parts por tema. Mide el grado promedio de reutilización de piezas dentro de una temática.
- `cant_sets` (Cuantitativa entera): Número de sets distintos en los que se incluye una minifigura específica.
- `n_colores` (Cuantitativa entera): Cantidad de tonos cromáticos distintos presentes en el inventario de un set.
- `log_piezas` y `log_piezas_unicas` (Cuantitativa continua): Transformación logarítmica ($\log_{10}$) del volumen de piezas para estabilizar varianzas asimétricas.

1.2.4. Hipótesis iniciales y supuestos de trabajo

- **Criterio de última versión de inventario:** Dado que `inventories.csv` posee múltiples revisiones históricas de un mismo set, se utilizó únicamente la última versión registrada. Esto evita ponderaciones duplicadas o sesgadas por revisiones de producción.

- **Exclusión de piezas de repuesto y no reales:** En el análisis de variaciones cromáticas se descartaron las piezas marcadas como repuesto (`is_spare = True`) y los identificadores de color no válidos (`-1` o `9999`).
- **Exclusión de minifiguras sueltas:** Se filtraron los inventarios marcados con el prefijo `fig-` en `set_num`, garantizando trabajar únicamente con minifiguras pertenecientes a algún set.

1.2.5. Nuevos features generados

- `tiene_subsets`: Flag booleano que determina si un set contiene sub-sets.
- `num_parts_subsets` y `num_parts_total`: Métrica corregida del total real de piezas acumulando las de sus sub-sets.
- `repetition_ratio`: Ratio de reutilización de piezas por temática.
- `categoria_exclusividad`: Variable categórica que clasifica a una minifigura en «Exclusiva» (1 set) o «Reutilizada» (≥ 2 sets).
- `tamaño`: Categorización ordinal del set según su número de piezas: Chico (≤ 50), Mediano (51–200), Grande (201–1000) y Muy Grande (> 1000).
- `exceso_colores`: Diferencia entre la cantidad de colores de un set y la mediana de su categoría de tamaño.
- `log_ratio`: logaritmo del cociente entre piezas totales y tipos de pieza distintos de un set. Mide cuántas veces se repite en promedio cada tipo de pieza.
- `colores_por_tipo` y `cats_por_tipo`: variedad cromática y de categorías relativizada por la cantidad de tipos de pieza, para independizarlas del tamaño del set.

1.2.6. Valores atípicos

Se empleó el criterio del Rango Intercuartílico (IQR $= Q3 - Q1$), definiendo límites en $Q1 - 1{,}5 \times \text{IQR}$ y $Q3 + 1{,}5 \times \text{IQR}$:

- **Análisis de Piezas Totales:** Se identificaron 2.359 valores atípicos superiores en `num_parts_total`.
- **Análisis de Ratio de Repetición:** Se detectaron valores atípicos severos en la parte superior, sobresaliendo de forma extrema el tema *Mosaic* (ratio $\approx 445{,}8$), seguido por *LEGO Art* y *Technic*.
- **Análisis de Colores y Piezas:** Se hallaron 1.681 atípicos superiores en número de piezas ($> 683{,}5$) y 678 atípicos superiores en variedad de colores ($> 28{,}5$).

Se decidió **no eliminar ningún valor atípico**. Los registros corresponden a sets reales de gran tamaño o patrones específicos (como los mosaicos). Para atenuar la asimetría severa sin perder información del dominio, se aplicó una transformación logarítmica ($\log_{10}$) sobre el eje de piezas en las visualizaciones y modelos linealizados.

1.2.7. Datos faltantes: proporción y tratamiento

- **Sets sin piezas registradas:** Se identificaron sets sin inventario cargado (`num_parts_total == 0`), los cuales se excluyeron del análisis al no ser posible estimar su contenido.
- **Inconsistencias por Minifiguras:** Se hallaron valores nulos en `theme_id` provenientes de registros de minifiguras vendidas por separado. Se resolvieron mediante el filtrado explícito de estos inventarios.
- **Inclusiones y Joins:** Tras realizar los cruces entre piezas, colores e inventarios, no se encontraron registros nulos en las variables clave (`year`, `theme_id`, `color_id`, `part_cat_id`, `quantity`).

1.2.8. Exploración inicial de variables

Entre las principales variables cuantitativas se encuentran year, num_parts, quantity y las variables derivadas relacionadas con cantidad de piezas, colores y reutilización.

Por otro lado, variables como theme_id, part_num, color_id, set_num y fig_num funcionan como identificadores o variables cualitativas nominales, aunque algunas estén codificadas numéricamente.

Para las variables cuantitativas se analizaron medidas descriptivas y distribuciones, mientras que para las variables cualitativas se estudiaron frecuencias y cantidad de categorías distintas. Este análisis permitió detectar una fuerte asimetría en variables asociadas al tamaño de los sets y diferencias importantes entre distintas temáticas de LEGO.

1.3. Preguntas de investigación

1.3.1. Pregunta 1: ¿Los sets que incluyen otros sets tienden a tener más piezas que aquellos que no incluyen sub-sets?

Según los criterios de Rebrickable, un sub-set es un modelo individual, completo e independiente que forma parte de un set con múltiples modelos. Para el análisis se utilizó únicamente la última versión disponible del inventario de cada set, evitando que un mismo set apareciera repetido y tuviera un peso desproporcionado en los resultados.

Además, se construyó la variable derivada `num_parts_total`, definida como la cantidad de piezas del set principal más las piezas aportadas por sus sub-sets. Esto resulta necesario dado que el campo `num_parts` de `sets.csv` no incluye las piezas correspondientes a dichos sub-modelos. También se generó la variable booleana `tiene_subsets`, que permite separar los sets según contengan o no al menos un sub-set.

Principales hallazgos:

Los sets que contienen sub-sets presentan una cantidad total de piezas claramente superior a aquellos que no los contienen. La mediana es de 256 piezas para los sets con sub-sets, frente a 60 piezas para los sets sin sub-sets. Esto implica que, en términos de mediana, los sets con sub-sets contienen aproximadamente 4,3 veces más piezas.

La misma tendencia se observa en la media: los sets con sub-sets presentan una media de 604,32 piezas, mientras que los sets sin sub-sets alcanzan una media de 233,50 piezas, aproximadamente 2,6 veces menos.

En ambos grupos la media es considerablemente superior a la mediana, lo que evidencia una distribución asimétrica hacia valores altos debido a la presencia de sets de gran tamaño. Por este motivo, la mediana resulta especialmente útil para representar el tamaño típico de cada grupo, ya que es menos sensible a los valores extremos.

El rango intercuartílico también refuerza esta diferencia. El 50 % central de los sets con sub-sets contiene entre 109 y 668 piezas, mientras que en los sets sin sub-sets se encuentra entre 19 y 234 piezas. Por lo tanto, la diferencia observada no se explica únicamente por unos pocos sets excepcionalmente grandes, sino que también se manifiesta en la región central de ambas distribuciones.

El boxplot permite observar este desplazamiento general hacia cantidades mayores de piezas en los sets con sub-sets. Debido a la fuerte asimetría de la variable y a la presencia de valores que abarcan varios órdenes de magnitud, se utilizó una escala logarítmica para facilitar la comparación visual.

A pesar de esta diferencia, existe una superposición considerable entre ambos grupos. Esto indica que la presencia de sub-sets no determina por sí sola que un set tenga una gran cantidad de piezas: existen sets sin sub-sets de gran tamaño y sets con sub-sets relativamente pequeños. Sin embargo, las medidas de tendencia central y dispersión muestran una asociación clara entre ambas variables.

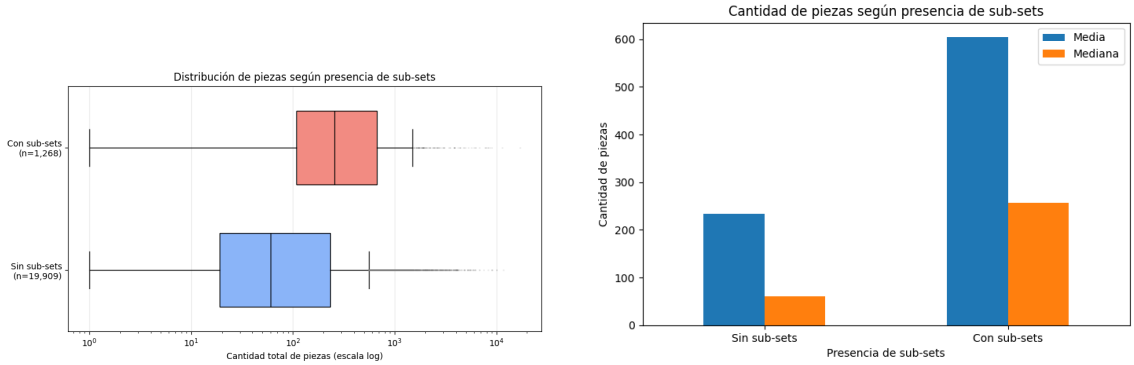


Figura 2: Gráficos sobre la cantidad de piezas según la presencia de sub-sets.

Conclusión:

Los resultados respaldan la hipótesis planteada: los sets que incluyen sub-sets tienden a presentar una mayor cantidad total de piezas que aquellos que no los incluyen. Esta diferencia se observa tanto en la media y la mediana como en el rango intercuartílico.

No obstante, el análisis muestra una asociación entre ambas variables y no permite establecer una relación causal entre la presencia de sub-sets y el tamaño del set. Tener sub-sets no implica necesariamente que un set vaya a ser de los más grandes: algunos pueden contener sub-sets pequeños, mientras que otros sets sin sub-sets pueden tener una gran cantidad de piezas.

1.3.2. Pregunta 2: ¿Existen temas que reutilicen una mayor proporción de tipos de piezas entre sus sets que otros?

Para analizar el grado de reutilización de piezas dentro de cada temática se utilizó únicamente la última versión disponible del inventario de cada set, siguiendo el mismo criterio aplicado previamente. Luego se relacionaron los inventarios con sus piezas y con el tema correspondiente a cada set.

Se excluyeron del análisis los inventarios correspondientes a minifiguras individuales, identificados mediante el prefijo `fig-`, ya que no poseen una correspondencia directa con `sets.csv` y no resultan relevantes para estudiar la reutilización de piezas entre temas de sets. Una vez excluidos estos registros, no quedaron valores faltantes en `theme_id`.

Para cada temática se calcularon las siguientes variables:

- `total_parts`: cantidad total de piezas contabilizadas en todos los sets del tema.
- `unique_parts`: cantidad de tipos distintos de piezas presentes en el tema.
- `repetition_ratio`: cociente entre ambas cantidades,

$$\text{repetition_ratio} = \frac{\text{total_parts}}{\text{unique_parts}}$$

Esta métrica permite interpretar cuántas veces aparece, en promedio, cada tipo de pieza dentro de una temática. Un valor cercano a 1 indica poca repetición, mientras que valores elevados representan una reutilización más intensa de un conjunto relativamente reducido de tipos de piezas.

Principales hallazgos:

Los resultados muestran diferencias marcadas en el grado de reutilización entre las distintas temáticas. El caso más extremo corresponde a *Mosaic*, con un `repetition_ratio` de aproximadamente 445,8. Este tema acumula 14.712 piezas utilizando únicamente 33 tipos distintos, lo que

evidencia una estrategia constructiva basada fuertemente en la repetición de un conjunto reducido de elementos.

También se observan valores elevados en temas como *LEGO Art* y *Technic*, aunque con una mayor diversidad de piezas. *Star Wars*, por ejemplo, presenta un ratio cercano a 95,1, indicando una reutilización importante pero combinada con una variedad considerablemente mayor de tipos de piezas.

El diagrama de dispersión permite observar que no existe una relación simple entre la cantidad de tipos de piezas disponibles en una temática y su nivel de repetición. Algunos temas pueden presentar una alta diversidad y, al mismo tiempo, reutilizar intensamente esas piezas, mientras que otros muestran valores bajos en ambas dimensiones.

El boxplot muestra una distribución fuertemente asimétrica hacia valores altos. Aplicando el criterio del rango intercuartílico se detectaron valores atípicos únicamente por encima del límite superior. Este comportamiento es esperable debido a la propia definición de la métrica: dado que la cantidad total de piezas no puede ser menor que la cantidad de tipos de piezas únicas,

$$\text{repetition_ratio} \geq 1$$

por lo que no se esperan valores atípicos inferiores. Los valores extremos/outliers no fueron eliminados, ya que corresponden a comportamientos reales del dominio y aportan información relevante sobre la forma en que se diseñan determinados temas.

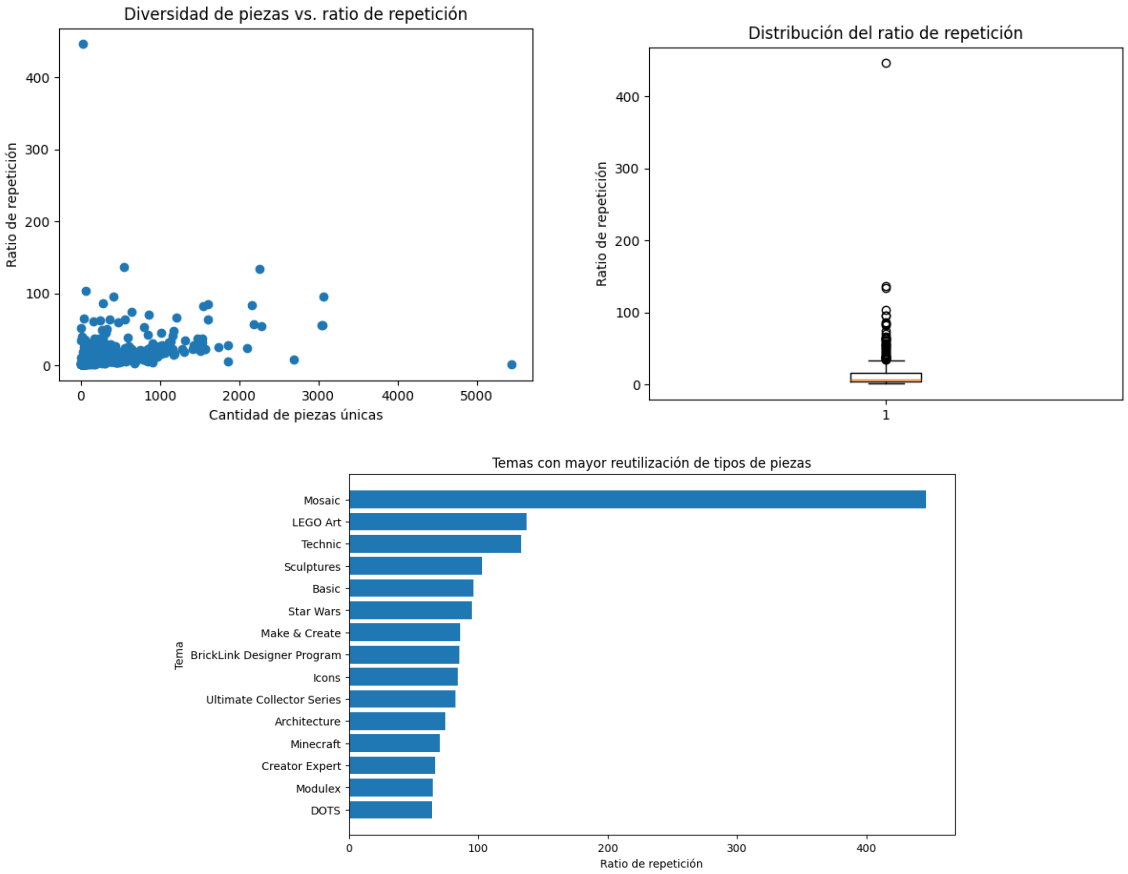


Figura 3: Gráficos sobre la reutilización de tipos de piezas por tema.

El gráfico de barras permite comparar directamente las temáticas con mayor `repetition_ratio`. La diferencia de *Mosaic* respecto del resto es especialmente marcada, mientras que otros temas presentan valores altos pero considerablemente menores.

Conclusión:

Los resultados respaldan la existencia de diferencias importantes entre temáticas en cuanto a la reutilización de piezas. Algunas líneas utilizan repetidamente un conjunto relativamente reducido de tipos de piezas, mientras que otras presentan una mayor diversidad y menor repetición.

Sin embargo, los ratios cercanos a 1 deben interpretarse con cautela, ya que pueden corresponder a temáticas con pocos sets o con un volumen reducido de piezas. Por ello, una posible alternativa para analizarlo podria ser decidir un número arbitrario mínimo de sets o de piezas por temática antes de realizar comparaciones, según lo que se busque analizar, evitando que grupos con muy poca información condicionen las conclusiones.

1.3.3. Pregunta 3: ¿Qué porcentaje de minifiguras son reutilizadas en múltiples sets frente a aquellas que son exclusivas?

Para este análisis se utilizó únicamente la última versión disponible del inventario de cada set, siguiendo el mismo criterio metodológico aplicado en las preguntas anteriores. Además, se excluyeron los inventarios correspondientes a minifiguras vendidas individualmente, identificadas mediante el prefijo `fig-`, ya que el objetivo es estudiar la presencia de minifiguras dentro de sets LEGO.

Para cada minifigura se contabilizó la cantidad de sets distintos en los que aparece. A partir de esta cantidad se definieron dos categorías:

- **Exclusiva**: aparece en exactamente un set.
- **Reutilizada**: aparece en dos o más sets.

Principales hallazgos:

El análisis muestra una clara predominancia de la exclusividad: el **80,3 %** de las minifiguras aparece en un único set, mientras que únicamente el **19,7 %** se reutiliza en dos o más sets.

Este resultado indica que, dentro del conjunto analizado, la mayoría de las minifiguras poseen una presencia muy acotada. Sin embargo, la reutilización no se distribuye de manera uniforme entre todas las figuras. Al analizar las minifiguras que aparecen en mayor cantidad de sets, se observan principalmente dos patrones.

Por un lado, aparecen personajes genéricos o elementos recurrentes de escenario, como policías, bomberos, esqueletos o astronautas, que pueden utilizarse en numerosos sets sin depender de un personaje específico. Por otro lado, también se encuentran protagonistas o figuras emblemáticas de temáticas con una gran cantidad de sets, como *Star Wars* o *Minecraft*, cuya recurrencia dentro de una misma línea favorece su reutilización.

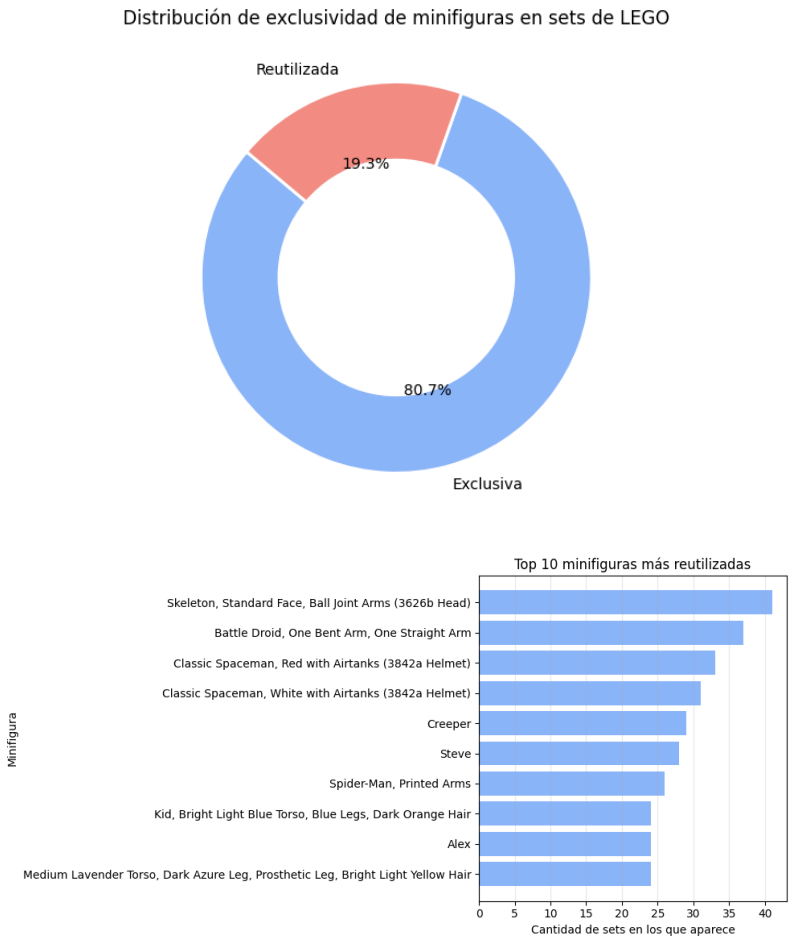


Figura 4: Distribución entre minifiguras exclusivas y reutilizadas, y minifiguras presentes en mayor cantidad de sets.

El gráfico de distribución evidencia visualmente la fuerte diferencia entre ambas categorías. A su vez, el gráfico de las minifiguras más reutilizadas permite observar que la reutilización se concentra en figuras con características particulares, ya sea por tratarse de personajes genéricos o por pertenecer a temáticas históricas o de alta producción.

Conclusión:

Los resultados muestran que la exclusividad es el comportamiento predominante entre las minifiguras analizadas. La reutilización representa una proporción minoritaria y parece concentrarse principalmente en figuras genéricas o en personajes recurrentes de temáticas con numerosos sets.

No obstante, este análisis es descriptivo y no permite afirmar que la exclusividad responda necesariamente a una estrategia comercial o de coleccionismo. Para evaluar esa hipótesis sería necesario incorporar información adicional sobre la temática, el año de lanzamiento, la producción de sets o la estrategia comercial asociada a cada línea.

1.3.4. Pregunta 4: ¿Los sets con más piezas usan también más colores distintos? ¿Esa relación cambia según el tema y la época?

Para este análisis se construyó un dataset con una fila por set utilizando únicamente la última versión disponible de cada inventario. Se excluyeron las piezas de repuesto, los inventarios correspondientes a minifiguras individuales y los identificadores de color que no representan colores reales. Además, se descartaron los sets con menos de 10 piezas, ya que en estos casos la cantidad posible de colores está fuertemente limitada por el propio tamaño del set y agregaba ruido a la

comparación.

Para cada set se calcularon, entre otras, las variables `num_piezas`, correspondiente a la cantidad total de piezas, y `n_colores`, que representa la cantidad de colores distintos utilizados. Debido a la fuerte asimetría en la cantidad de piezas, también se generó la transformación $\log_{10}(\text{num_piezas})$ para analizar con mayor claridad su relación con la variedad cromática.

Principales hallazgos:

Se observa una asociación positiva entre el tamaño del set y la cantidad de colores distintos utilizados. La correlación de Pearson entre `num_piezas` y `n_colores` es de $r = 0,53$, mientras que al utilizar el logaritmo de la cantidad de piezas aumenta a $r = 0,69$. La relación, por lo tanto, se representa mejor en escala logarítmica que en escala lineal.

Esta tendencia también se observa al dividir los sets en categorías de tamaño. La mediana de colores aumenta progresivamente desde 6 colores en los sets chicos, hasta 9 en los medianos, 16 en los grandes y 23 en los muy grandes. Esto indica que los sets más grandes tienden a utilizar paletas de colores más amplias.

Sin embargo, la cantidad de piezas no explica por completo la variedad cromática. En el gráfico de dispersión se observa una dispersión considerable: para cantidades similares de piezas existen sets con cantidades de colores muy diferentes. Además, la cantidad de colores presenta una correlación ligeramente mayor con la cantidad de tipos de piezas distintas ($r = 0,75$) y con la cantidad de categorías de piezas ($r = 0,76$) que con el tamaño total del set. Esto sugiere que la variedad cromática está relacionada no solo con cuántas piezas contiene un set, sino también con la diversidad de elementos utilizados en su construcción.

A lo largo del tiempo también se observa un aumento de la variedad cromática: la mediana de colores creció de 2 colores en la década de 1950 a 15 colores en la década de 2020.

Análisis por temática:

Para estudiar si esta relación cambia según la temática se consideraron únicamente aquellas con al menos 30 sets, evitando obtener conclusiones a partir de grupos con muy pocas observaciones.

Como los temas compuestos por sets grandes tienden naturalmente a utilizar más colores, se controló el efecto del tamaño comparando la cantidad de colores de cada set con la mediana correspondiente a su categoría de tamaño. De esta manera se construyó la variable `exceso_colores`, que representa cuántos colores utiliza un set por encima o por debajo de lo esperado para sets de un tamaño similar.

Al controlar por tamaño, temas orientados a personajes y fantasía (*Elves*, *Classic*, *Disney Princess*) emplean entre +8 y +11 colores adicionales sobre la mediana de su categoría, mientras que líneas de colección o réplicas (*Architecture*, *Expert Builder*) utilizan menos.

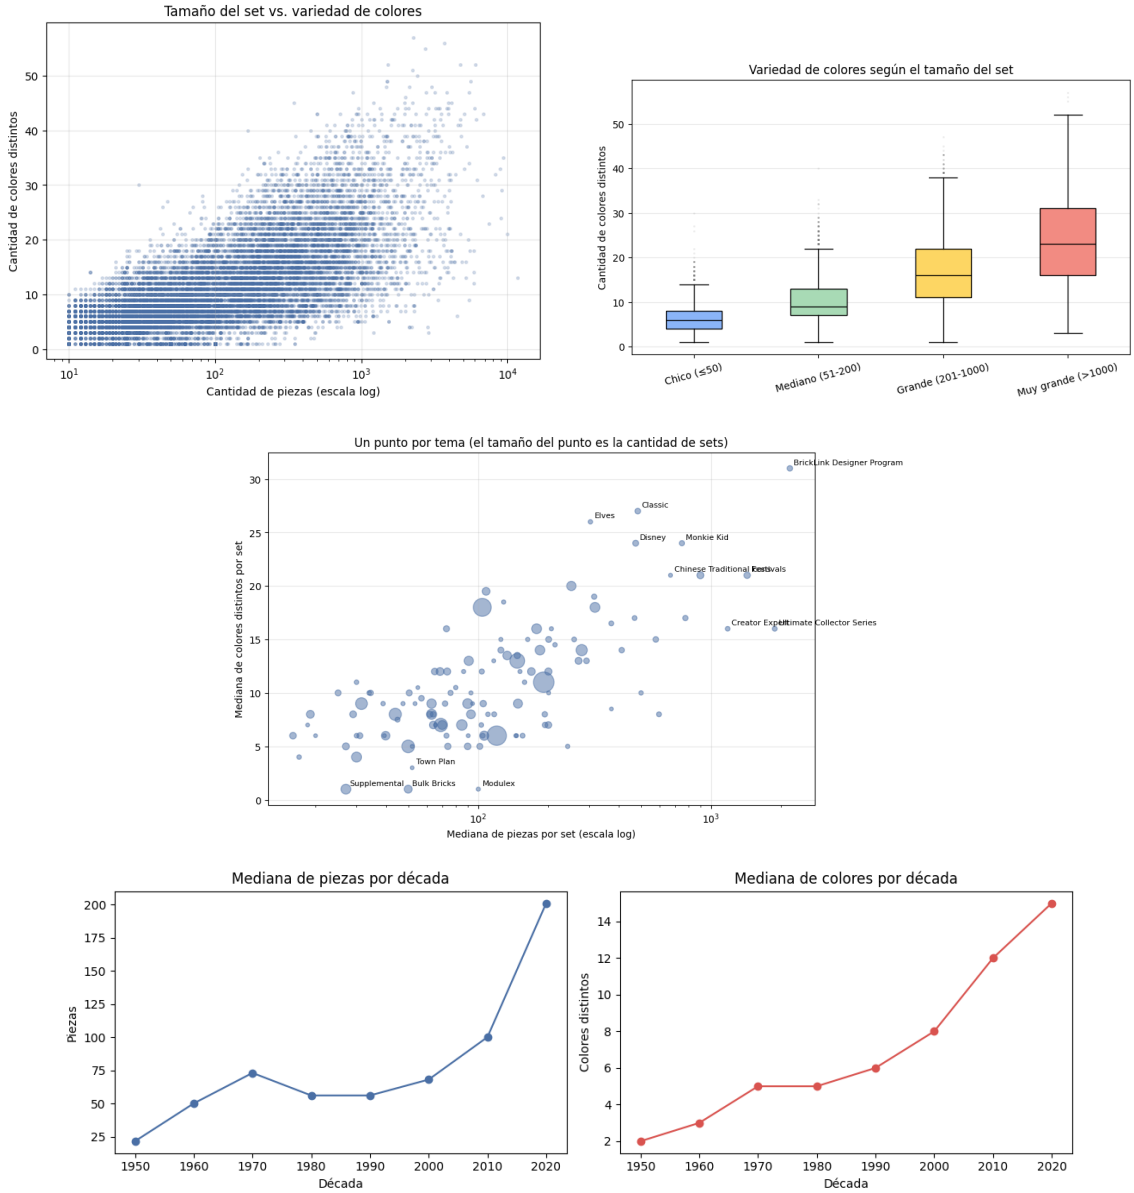


Figura 5: Visualizaciones del análisis de variedad cromática según tamaño, tema y época.

Conclusión:

Los resultados respaldan la existencia de una asociación positiva entre el tamaño del set y la cantidad de colores distintos utilizados. Sin embargo, el tamaño no explica por sí solo la variedad cromática: también pueden influir otros factores como la diversidad de tipos de piezas, la temática y la época de lanzamiento.

En particular, algunos temas utilizan sistemáticamente más o menos colores que otros aún comparando sets de tamaño similar, y la cantidad de colores aumentó a lo largo de las décadas. Por lo tanto, la variedad cromática parece responder a una combinación de factores y no únicamente a la cantidad total de piezas.

1.4. Agrupamiento

1.4.1. Objetivo y unidad de análisis

A diferencia de las preguntas anteriores, donde se partió de hipótesis definidas previamente, en esta sección se busca determinar si los sets se organizan en grupos naturales no definidos de antemano, aplicando el algoritmo K-Means.

La unidad de análisis es el set: cada observación corresponde a un set completo, descrito mediante variables numéricas que resumen su composición. Se trata de una tarea de aprendizaje no supervisado, por lo que no existe una variable objetivo y la interpretación de los grupos obtenidos se realiza a posteriori.

1.4.2. Variables utilizadas y justificación

Las variables de conteo disponibles a nivel de set (`num_piezas`, `piezas_unicas`, `n_colores` y `n_categorias`) presentan correlaciones de entre 0,53 y 0,87 entre sí, dado que todas reflejan en buena medida una misma dimensión subyacente: el tamaño del set. Como K-Means asigna cada observación al centroide más cercano y la distancia se calcula sumando las diferencias en todas las variables, el uso directo de estas cuatro variables implicaría que el tamaño pondere cuatro veces sobre el resto, produciendo una partición determinada casi exclusivamente por esa dimensión.

Para evitarlo se reemplazaron las variables de conteo por variables relativas, que expresan proporciones en lugar de magnitudes absolutas. Con las cinco variables finales la correlación máxima entre pares desciende de 0,87 a 0,53.

Variable	Qué mide	Cálculo
`log_piezas`	Tamaño del set	$\log_{10}$(num_piezas)
`log_ratio`	Repetición media por tipo de pieza	$\log_{10}$(num_piezas/piezas_unicas)
`colores_por_tipo`	Variedad cromática relativa	n_colores / piezas_unicas
`cats_por_tipo`	Variedad de categorías relativa	n_categorias / piezas_unicas
`pct_transparentes`	Proporción de piezas transparentes	piezas transparentes / num_piezas

Cuadro 1: Variables utilizadas en el agrupamiento.

Se decidió no incorporar el año de lanzamiento como variable de agrupamiento. Por su rango amplio y su fuerte estructura temporal, tendería a particionar los grupos por década, lo que responde una pregunta distinta de la planteada. El año se utiliza posteriormente en la caracterización de los grupos obtenidos.

Asimismo, se evaluó incorporar la cantidad de minifiguras por cada cien piezas como sexta variable. Su inclusión deterioró la calidad del agrupamiento: el coeficiente de Silhouette para $k = 3$ descendió de 0,353 a 0,279 y se perdió la estructura de los grupos obtenidos. El resultado es consistente con el dominio, dado que solo el 46 % de los sets contiene al menos una minifigura, por lo que la variable toma valor cero en la mayoría de las observaciones. Se descartó su incorporación.

1.4.3. Transformaciones aplicadas

El dataset utilizado replica los criterios metodológicos de la Pregunta 4: última versión del inventario de cada set, exclusión de piezas de repuesto, exclusión de los colores -1 y 9999, y exclusión de los sets con menos de diez piezas. El conjunto resultante contiene **15.982 sets** y no presenta valores nulos en las variables utilizadas.

Sobre ese conjunto se aplicaron dos transformaciones:

- **Acotamiento de valores extremos (winsorización) al percentil 99.** Dado que `MinMaxScaler` define la escala a partir del mínimo y el máximo observados, un único valor extremo determina el rango completo de una variable. Al escalar sin tratamiento previo, `colores_por_tipo`

presentaba una media de 0,012: un set con un solo tipo de pieza en treinta colores fijaba el máximo y comprimía al resto de las observaciones contra el cero, anulando el aporte de la variable al cálculo de distancias. Los valores por encima del límite se reemplazaron por el valor del límite, de modo que no se eliminó ninguna observación.

- **Normalización con `MinMaxScaler`.** Lleva cada variable al rango $[0, 1]$, de forma que todas contribuyan en igual magnitud al cálculo de distancias.

Cabe señalar la diferencia con el criterio adoptado en las preguntas de investigación, donde los valores atípicos se conservaron sin modificación por corresponder a sets reales. Ese criterio se mantiene para el análisis exploratorio. El acotamiento aplicado responde a un requerimiento técnico del escalado y afecta únicamente a la matriz utilizada por el algoritmo, no a las variables originales ni a los análisis previos.

1.4.4. Tendencia al clustering

Previo a la aplicación del algoritmo se evaluó si los datos presentan estructura de agrupamiento, dado que K-Means produce particiones incluso sobre datos distribuidos de forma uniforme, en cuyo caso los grupos serían un artificio del método.

Se utilizó el estadístico de Hopkins, que compara la distancia entre las observaciones reales y sus vecinos más cercanos contra la que se obtendría bajo una distribución uniforme en el mismo espacio. Valores próximos a 0,5 indican ausencia de estructura y valores próximos a 1 indican concentración en regiones. Calculado sobre cinco muestras de mil observaciones, el estadístico arrojó un valor promedio de **0,894**, lo que justifica la aplicación de técnicas de agrupamiento.

1.4.5. Estimación de la cantidad de grupos

Se evaluaron valores de k entre 2 y 10 mediante dos criterios complementarios. El método del codo analiza la inercia, que decrece monótonamente con k, por lo que se busca el punto a partir del cual el agregado de un grupo deja de producir una mejora apreciable. El coeficiente de Silhouette compara, para cada observación, su distancia promedio a las de su propio grupo contra la correspondiente al grupo vecino más cercano, tomando valores entre -1 y 1.

k	Inercia	Silhouette
2	2141.7	0.332
3	1711.5	**0.353**
4	1440.5	0.285
5	1237.4	0.269
6	1060.4	0.281
7	964.0	0.255
8	891.4	0.263
9	832.6	0.263
10	783.5	0.268

Cuadro 2: Inercia y coeficiente de Silhouette según la cantidad de grupos.

Ambos criterios coinciden en $k = 3$. La inercia cae un 20 % al pasar de dos a tres grupos y las reducciones posteriores son menores y decrecientes, lo que ubica el codo en ese valor. El coeficiente de Silhouette alcanza allí su máximo (0,353) y desciende para valores mayores. La coincidencia de ambos criterios sustenta la elección.

El valor de 0,353 corresponde a una estructura de agrupamiento moderada: los grupos existen pero presentan superposición en sus fronteras. Es un valor esperable en datos reales y notoriamente inferior al que se obtiene en conjuntos construidos con grupos bien separados.

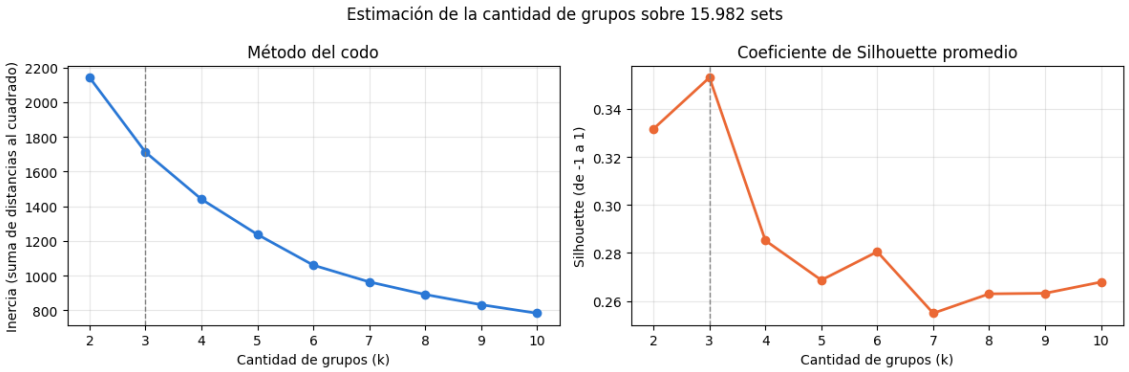


Figura 6: Método del codo y coeficiente de Silhouette promedio según la cantidad de grupos.

1.4.6. Evaluación de la calidad de los grupos

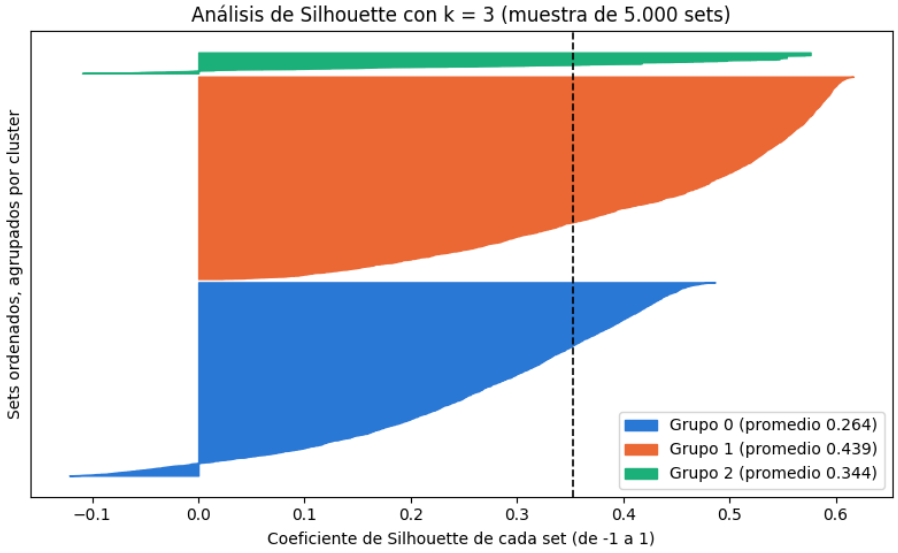


Figura 7: Análisis de Silhouette con $k = 3$ sobre una muestra de 5.000 sets.

El análisis de Silhouette por grupo arroja 0,264 para el grupo 0, 0,439 para el grupo 1 y 0,344 para el grupo 2. No se observan valores negativos de magnitud relevante, lo que indica que prácticamente ninguna observación quedó asignada a un grupo distinto del más cercano. El grupo 1 es el de mayor cohesión y el grupo 0 el de menor.

1.4.7. Visualización de los grupos

Dado que las cinco variables no pueden representarse simultáneamente en dos dimensiones, se aplicó Análisis de Componentes Principales con el único fin de visualizar el resultado. El agrupamiento se realizó sobre las cinco variables originales. Las dos primeras componentes conservan el 72 % de la variabilidad total.

El grupo 2 aparece claramente separado del resto. La frontera entre los grupos 0 y 1, en cambio, es una recta, comportamiento característico de K-Means al aplicarse sobre una distribución continua: el algoritmo particiona el espacio en regiones delimitadas por hiperplanos, exista o no una separación real en los datos. Esto sugiere que los grupos 0 y 1 corresponden a los extremos de un mismo gradiente y no a dos poblaciones diferenciadas, lo que resulta coherente con el coeficiente de Silhouette obtenido.

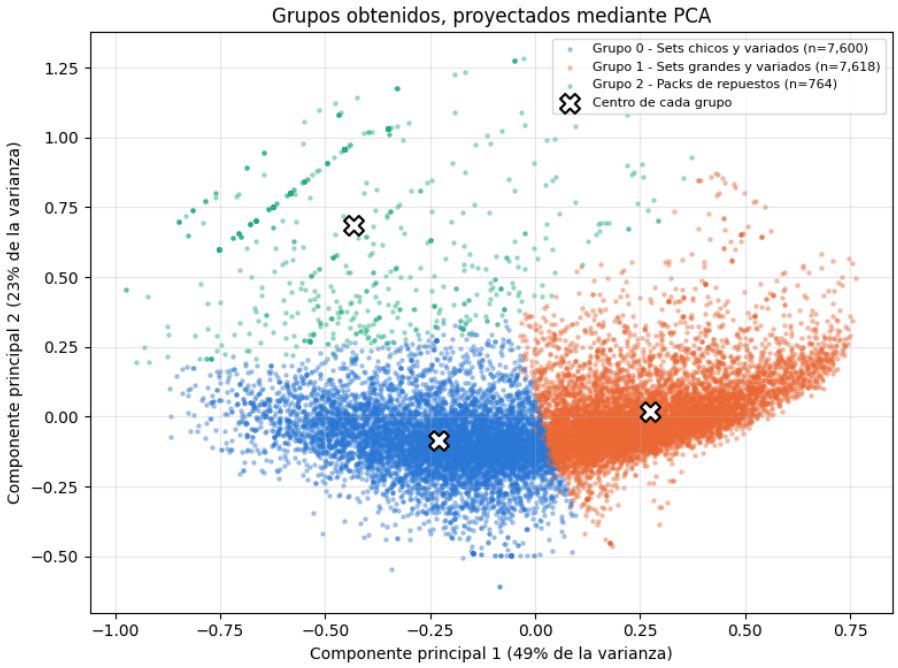


Figura 8: Grupos obtenidos, proyectados mediante PCA.

1.4.8. Caracterización de los grupos

Grupo	Sets	Piezas	Tipos	Repetición	Colores	Col./tipo	Silhouette
0	7.600	37	19	1.90	7	0.38	0.264
1	7.618	319	82	4.07	15	0.17	0.439
2	764	45	2	20.00	2	1.00	0.344

Cuadro 3: Caracterización de los grupos (medianas en unidades originales).

- **Grupo 2 — Packs de repuestos (764 sets).** Mediana de 45 piezas correspondientes a solo 2 tipos distintos, con cada tipo repetido veinte veces, y 2 colores. Sus temas más frecuentes son Technic, Bulk Bricks, Supplemental, Basic Set y DOTS. No constituyen modelos de construcción sino conjuntos de piezas sueltas.
- **Grupo 1 — Sets grandes y variados (7.618 sets).** Mediana de 319 piezas, 82 tipos distintos y 15 colores. Predominan Star Wars, Technic, Friends, Ninjago y Creator 3-in-1.
- **Grupo 0 — Sets chicos y variados (7.600 sets).** Mediana de 37 piezas pero 19 tipos distintos, es decir, prácticamente sin repetición de piezas. Entre sus temas más frecuentes se encuentran Star Wars, Friends, Bionicle, Classic Town y Town.

El agrupamiento no se estructura en función del tamaño sino del **grado de repetición de piezas**: el grupo 2 repite cada tipo unas veinte veces, el grupo 1 unas cuatro y el grupo 0 menos de dos. El tamaño diferencia al grupo 1 del grupo 0, pero no explica la separación del grupo 2, cuyo tamaño mediano es comparable al del grupo 0. Este resultado es consecuencia directa del reemplazo de las variables de conteo correlacionadas por variables relativas.

La composición temática del grupo 2 constituye una validación externa del resultado: los temas Bulk Bricks y Supplemental corresponden efectivamente a conjuntos de piezas sueltas según la clasificación de Rebrickable, categoría que el algoritmo identificó sin recibir esa información.

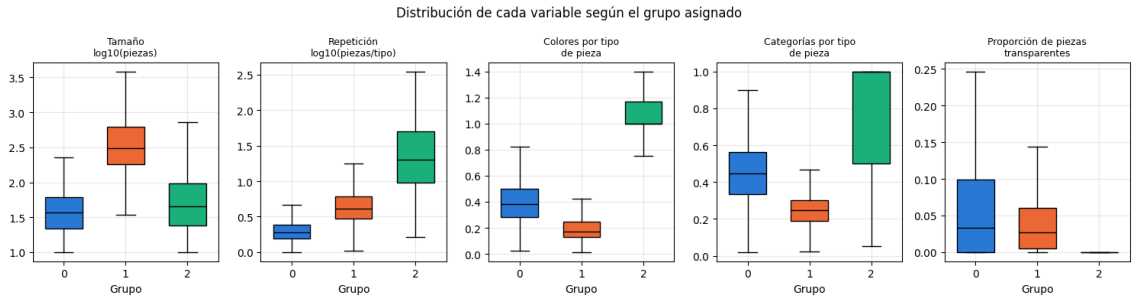


Figura 9: Distribución de cada variable según el grupo asignado.

1.4.9. Limitaciones

El coeficiente de Silhouette de 0,353 evidencia superposición entre grupos, particularmente entre el 0 y el 1. La frontera recta entre ambos en la proyección sugiere que responden a un gradiente continuo más que a dos poblaciones diferenciadas. K-Means asume grupos de forma esférica y tamaño similar, supuestos que no se verifican plenamente en esta estructura. Como trabajo futuro podría evaluarse un método de agrupamiento basado en densidad, que no impone esas restricciones y permitiría identificar observaciones no pertenecientes a ningún grupo.

1.5. Conclusiones

1.5.1. Principales hallazgos del análisis

El análisis exploratorio permitió entender la estructura del ecosistema LEGO en Rebrickable:

- La presencia de sub-sets está asociada con el volumen total de piezas.
- Existen diferencias marcadas en el grado de reutilización de piezas entre los distintos temas.
- Existe una estrategia comercial enfocada en la exclusividad de minifiguras (80.3 %), reservando la reutilización a elementos de escenario genéricos o personajes centrales.
- La variedad de colores crece de forma sublineal en relación al tamaño del modelo y está fuertemente determinada por la temática del set (fantasía vs. arquitectura) y su época de lanzamiento.
- Los sets se agrupan naturalmente en tres categorías determinadas por el grado de repetición de piezas antes que por el tamaño, siendo la más nítida la de los conjuntos de piezas sueltas.

2. Ejercicio 2: Modelos de regresión

2.1. Introducción

En este ejercicio se trabajó con el dataset de publicaciones de Airbnb de la ciudad de **Milán**, obtenido de Inside Airbnb. A partir de estos datos, se entrenaron y compararon dos modelos de regresión para predecir el precio de alquiler por noche de un alojamiento.

2.1.1. Objetivo

El objetivo es preparar el dataset para el modelado, entrenar una regresión lineal múltiple y un modelo de elección (Random Forest), utilizando una partición del 80 % para entrenamiento y del 20 % para prueba. Finalmente, se evalúa el desempeño mediante métricas de regresión y se selecciona el modelo más adecuado para predecir el precio.

2.2. Dataset

2.2.1. Descripción del dataset

Se utilizó el archivo `listings.csv.gz`, con **25.750 registros** y **90 columnas** originales. Cada registro corresponde a una publicación de Airbnb y la variable objetivo es `price`, que representa el precio por noche en euros.

Además, para construir variables relacionadas con la ubicación, se incorporó el dataset de estaciones de metro de la Comuna de Milán (`tpl_metrofermate.csv`).

2.2.2. Variables relevantes

Las principales variables consideradas fueron:

- **Ubicación:** `latitude`, `longitude` y `neighbourhood_cleansed`.
- **Características del alojamiento:** `room_type`, `accommodates`, `bedrooms`, `bathrooms` y `beds`.
- **Actividad y reseñas:** `number_of_reviews`, `reviews_per_month`, `review_scores_*` y `estimated_occupancy_l365d`.
- **Anfitrión y disponibilidad:** `calculated_host_listings_count`, `host_location`, `license`, `availability_30/90/365` y `minimum_nights`.

2.2.3. Datos faltantes: proporción y tratamiento

Se analizaron los valores faltantes y se aplicaron los siguientes tratamientos:

- **Columnas vacías:** se eliminaron `neighborhood_overview` y `host_since`, ya que no contenían datos en ningún registro.
- **Precio:** se eliminaron las 2.813 filas sin precio, porque no permiten entrenar ni evaluar los modelos.
- **Reseñas:** los nulos de `reviews_per_month` coincidían con los alojamientos sin reseñas (`number_of_reviews = 0`), por lo que se reemplazaron por 0. Para las variables de días desde la primera y la última reseña se asignó -1 cuando no había reseñas.
- **Baños:** se completó `bathrooms` a partir del texto de `bathrooms_text` (por ejemplo, "1.5 baths"), verificando la correspondencia con los valores conocidos. Los faltantes restantes se completaron con la mediana.

- **Ubicación del anfitrión y licencia:** los valores faltantes de `host_location` se agruparon como *Unknown*, mientras que los de `license` se clasificaron como *Not specified*.
- **Nulos restantes:** después de dividir los datos, se completaron con la mediana calculada exclusivamente sobre el conjunto de entrenamiento, evitando utilizar información del conjunto de prueba para el preprocesamiento.

2.2.4. Nuevas variables generadas

Se construyeron las siguientes variables para representar características adicionales de los alojamientos:

- `has_reviews`: variable booleana que indica si el alojamiento tiene al menos una reseña.
- `days_since_first_review` y `days_since_last_review`: días transcurridos desde la primera y la última reseña hasta la fecha de relevamiento. Se asignó -1 cuando no había reseñas.
- `distance_to_duomo`: distancia calculada a partir de las coordenadas geográficas del alojamiento y del Duomo de Milán.
- `distance_to_nearest_metro`: distancia calculada a partir de las coordenadas del alojamiento y de la estación de metro más cercana.
- `host_location`: se agruparon las ubicaciones en las categorías *Milan*, *Unknown* y *Other*, reuniendo en esta última los países con menos de 20 anfitriones.
- `license`: se agruparon los valores en cuatro categorías: *Licensed*, *Applied*, *Exempt* y *Not specified*.

2.2.5. Variables eliminadas

Se eliminaron variables que no aportaban información útil, podían generar fuga de información o presentaban redundancia:

- **Sin información útil para el modelo:** URLs, identificadores técnicos, `host_name` y `host_profile_id`.
- **Fuga de información (data leakage):** las variables `price_quote_*`, por su correlación perfecta con `price`, y `estimated_revenue_l365d`, calculada a partir del precio.
- **Redundancia y multicolinealidad:** se eliminaron variables con correlaciones superiores a 0.9 o que eran combinaciones lineales de otras, como ciertas variantes de `minimum_nights` y `maximum_nights`, `availability_60`, `number_of_reviews_ly`, `host_listings_count` y los desgloses por tipo de habitación de `calculated_host_listings_count`. Esta reducción buscó evitar redundancias y mejorar la estabilidad e interpretabilidad de los coeficientes de la regresión lineal.

2.2.6. Valores atípicos

La distribución de `price` presentaba una fuerte asimetría hacia la derecha, con algunos precios extremadamente altos. Se eliminaron los precios iguales a cero y los superiores al percentil 99, dado que estos valores podían influir considerablemente en el ajuste de la regresión lineal, que minimiza el error cuadrático. Luego de este filtro, el dataset quedó con **22.707 registros**.

2.2.7. Preparación para el modelado

Para preparar los datos se realizaron las siguientes transformaciones:

- Se convirtió `price` de texto (por ejemplo, "$1,234.00") a un valor numérico.
- Las variables categóricas, como `room_type`, `neighbourhood_cleansed`, `host_location` y `license`, se transformaron en variables indicadoras (*dummies*), eliminando una categoría de referencia mediante `drop_first=True`.
- El dataset se dividió en **18.165 registros de entrenamiento** (80 %) y **4.542 de prueba** (20 %).

2.2.8. Exploración de variables

Antes de entrenar los modelos se analizó la relación entre las variables predictoras y el precio. La Figura 10 muestra la matriz de correlación entre las doce variables más asociadas con `price`.

Las relaciones individuales con el precio son moderadas: la más alta corresponde a `accommodates` ($r = 0{,}41$), seguida por `bedrooms` (0,40) y `bathrooms` (0,35), mientras que `distance_to_duomo` presenta una asociación negativa ($r = -0{,}23$). Ninguna variable explica el precio por sí sola.

Además, se observa una fuerte correlación entre las variables de tamaño (`accommodates`, `beds` y `bedrooms`, entre 0,65 y 0,75) y entre las categorías de licencia (−0,90), lo que anticipa problemas de multicolinealidad en la regresión lineal.

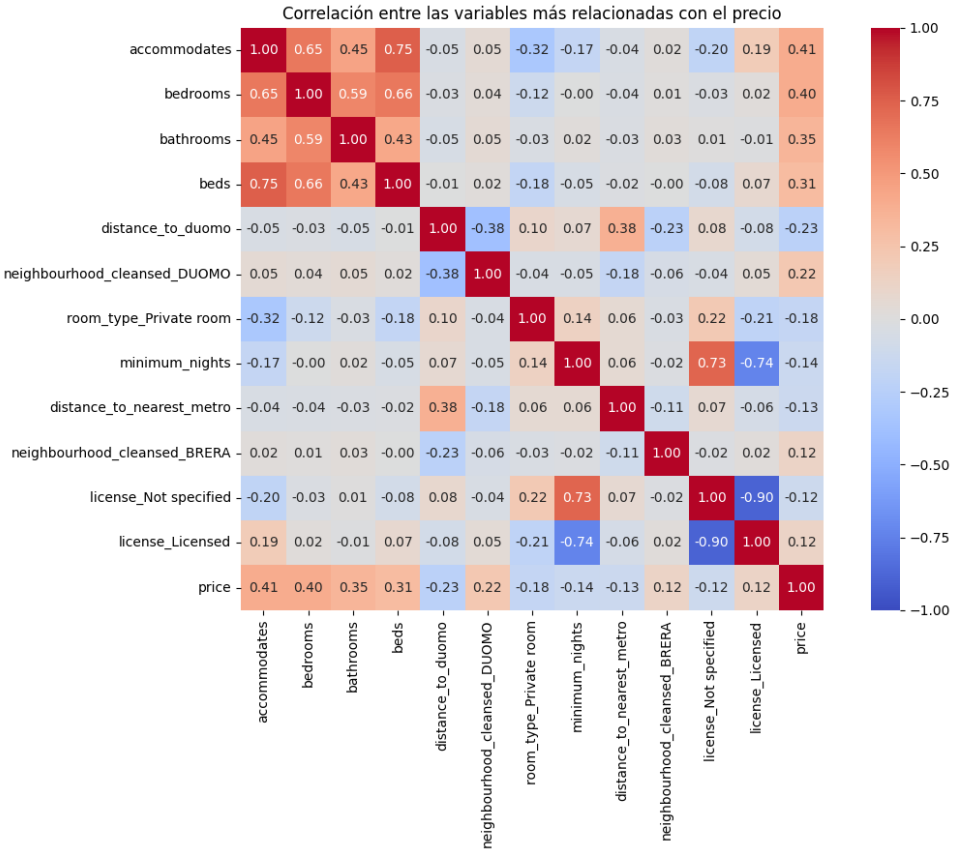


Figura 10: Correlación entre las variables más relacionadas con el precio.

La Figura 11 muestra la forma de las dos relaciones principales. El precio disminuye a medida

que aumenta la distancia al Duomo, aunque con una dispersión considerable, lo que explica la correlación moderada. Por otro lado, la mediana del precio crece de forma sostenida con la capacidad del alojamiento hasta aproximadamente 12 huéspedes; a partir de ese valor hay pocas observaciones y el comportamiento es más irregular.

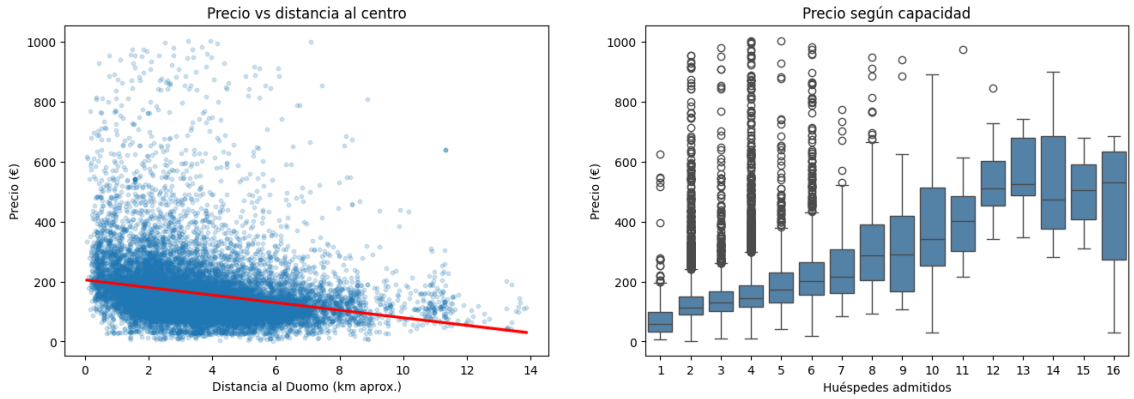


Figura 11: Precio según la distancia al Duomo y la capacidad del alojamiento.

2.3. Modelos entrenados

2.3.1. Regresión lineal múltiple

Variables utilizadas:

Se utilizaron las variables numéricas del dataset limpio, excluyendo identificadores, la variable objetivo `price` y las variables descartadas previamente, junto con las variables indicadoras de las categorías. Las variables predictoras se estandarizaron (media 0 y desvío estándar 1) para facilitar la comparación de sus coeficientes. La interpretación de los coeficientes en euros depende de la escala utilizada para la variable objetivo; por ello, se consideraron los coeficientes transformados a la escala original cuando correspondía.

Evaluación en entrenamiento y prueba:

Conjunto	R^2	MSE	RMSE (€)
Train	0.352	7295.99	85.42
Test	0.354	7527.98	86.76

Cuadro 4: Métricas de la regresión lineal múltiple.

Principales hallazgos:

El desempeño en entrenamiento y prueba es similar, sin una brecha importante entre ambos conjuntos. Sin embargo, el modelo explica aproximadamente el 35 % de la variabilidad observada en los precios, por lo que su capacidad predictiva es limitada.

Entre las asociaciones más relevantes identificadas por los coeficientes se encuentran:

- **Ubicación:** la distancia al Duomo y la pertenencia al barrio Duomo se relacionan con diferencias en el precio. La magnitud de estas asociaciones debe interpretarse según la unidad de la variable de distancia.
- **Tamaño:** el número de dormitorios, baños y huéspedes admitidos presenta una asociación positiva con el precio.
- **Tipo de alojamiento:** las habitaciones privadas presentan, en promedio y manteniendo constantes las demás variables, un precio estimado inferior al de los alojamientos enteros.

- **Estadía mínima y actividad:** una mayor cantidad de noches mínimas, más reseñas y una mayor ocupación se asociaron con precios estimados más bajos, manteniendo constantes las demás variables.

Estas interpretaciones describen asociaciones estimadas por el modelo y no implican necesariamente relaciones causales.

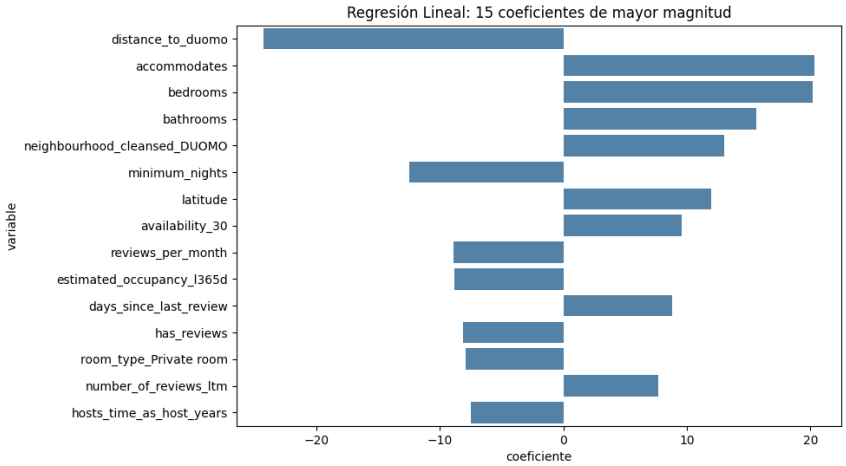


Figura 12: Regresión lineal: 15 coeficientes de mayor magnitud.

2.3.2. Modelo a elección: Random Forest

Justificación:

La regresión lineal explicó aproximadamente el 35 % de la variabilidad del precio. Por este motivo, se evaluó Random Forest, un modelo que puede captar relaciones no lineales e interacciones entre variables. Además, combina múltiples árboles de decisión y no requiere estandarizar las variables numéricas.

Optimización de hiperparámetros:

Se utilizó `GridSearchCV` con validación cruzada de 3 particiones (*folds*) sobre el conjunto de entrenamiento, seleccionando la combinación con menor RMSE promedio. Por el tiempo de cómputo, se fijaron `n_estimators = 100` y `max_features = "sqrt"`, mientras que se probaron los valores 15 y 25 para `max_depth`, y 2 y 5 para `min_samples_leaf`. La mejor combinación fue `max_depth = 25` y `min_samples_leaf = 2`, con un RMSE promedio de validación cruzada de 82.04 €.

Evaluación en entrenamiento y prueba:

Conjunto	R^2	MSE	RMSE (€)
Train	0.775	2531.47	50.31
Test	0.415	6811.94	82.53

Cuadro 5: Métricas del modelo Random Forest.

Principales hallazgos:

Random Forest obtiene un mejor resultado que la regresión lineal en el conjunto de prueba, con un R^2 de 0.415 frente a 0.354. No obstante, la diferencia entre entrenamiento y prueba evidencia cierto sobreajuste.

Las variables con mayor importancia para el modelo incluyen características del tamaño del alojamiento (`accommodates`, `bedrooms`, `bathrooms` y `beds`) y de su ubicación (`distance_to_duomo`,

`latitude` y el barrio Duomo). A diferencia de los coeficientes de la regresión lineal, las importancias no indican si la relación con el precio es positiva o negativa.

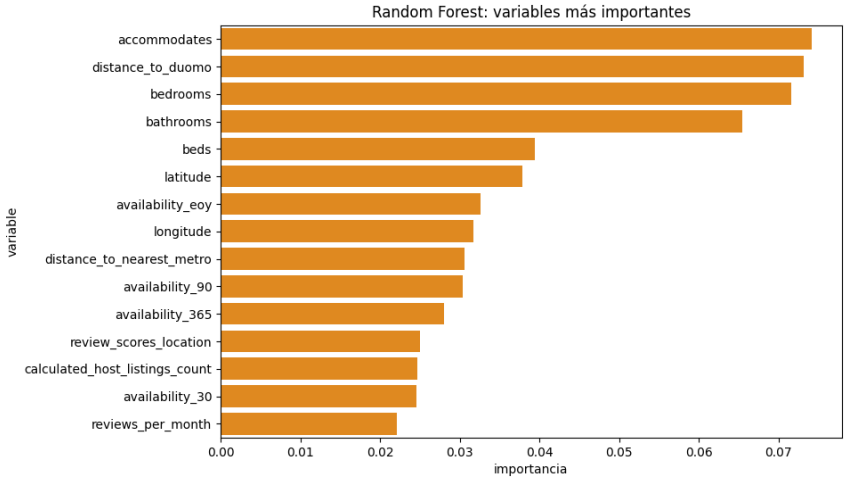


Figura 13: Random Forest: 15 variables más importantes.

2.4. Cuadro comparativo de resultados en prueba

Modelo	MSE	RMSE (€)	R^2
Regresión lineal	7527.98	86.76	0.354
Random Forest	6811.94	82.53	0.415

Cuadro 6: Comparación de los modelos sobre el conjunto de prueba.

En qué consiste cada modelo:

- **Regresión lineal:** estima el precio como una combinación lineal de las variables predictoras, buscando minimizar el error cuadrático. Es relativamente simple e interpretable, pero no representa directamente relaciones no lineales.
- **Random Forest:** combina múltiples árboles de decisión entrenados sobre muestras aleatorias de los datos y utiliza sus predicciones conjuntas. Puede captar relaciones no lineales e interacciones entre variables.

Desempeño respecto del conjunto de entrenamiento:

- **Regresión lineal:** las métricas de entrenamiento y prueba son similares (R^2 de 0.352 en train y 0.354 en test), lo que indica que no se observa una brecha de generalización importante.
- **Random Forest:** el rendimiento es considerablemente mejor en entrenamiento ($R^2 = 0{,}775$ y RMSE de 50.31 €) que en prueba ($R^2 = 0{,}415$ y RMSE de 82.53 €), lo que evidencia sobreajuste. Sin embargo, el RMSE de prueba es cercano al obtenido en validación cruzada (82.04 €), lo que respalda la consistencia de esa estimación del error.

El RMSE es la raíz cuadrada del promedio de los errores al cuadrado. Se expresa en euros y penaliza más los errores grandes, por lo que permite interpretar el error típico de predicción en la escala del precio.

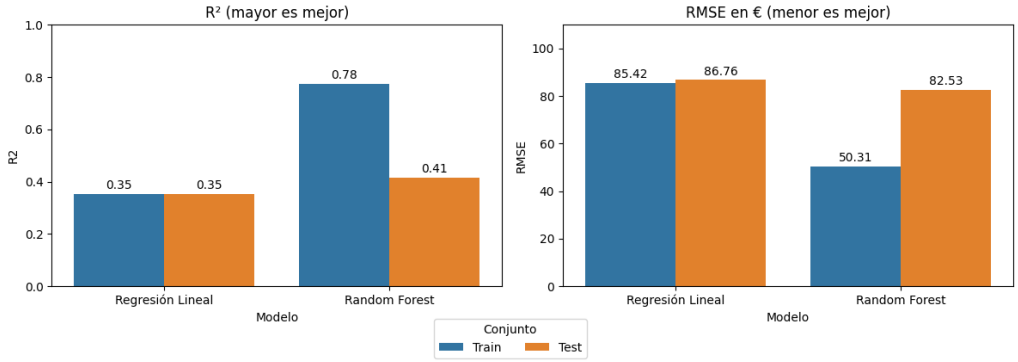


Figura 14: Comparación de R^2 y RMSE de ambos modelos en entrenamiento y prueba.

2.5. Elección del modelo

Se elegiría **Random Forest** para predecir el precio por noche de un alojamiento de Airbnb en Milán, ya que obtiene un mejor desempeño en el conjunto de prueba, que permite evaluar su comportamiento ante datos no utilizados durante el entrenamiento. Explica el 41.5 % de la variabilidad del precio, frente al 35.4 % de la regresión lineal, y reduce el RMSE de 86.76 € a 82.53 €, aproximadamente un 4.9 %.

La regresión lineal sigue siendo útil para interpretar las asociaciones entre las variables y el precio, mientras que Random Forest ofrece una mejor capacidad predictiva en esta comparación. Ambos modelos destacan la importancia de las características del alojamiento y de su ubicación.

De todas formas, la mejora obtenida es moderada y ninguno de los dos modelos explica más de la mitad de la variabilidad de los precios. Esto sugiere que también influyen otros factores que no están representados adecuadamente en el dataset, como la calidad del alojamiento, las fotografías, los servicios ofrecidos o la temporada.

3. EJERCICIO 3: Competencia de Machine Learning

3.1. Preprocesamiento del Dataset

3.1.1. Preprocesamiento y Feature Engineering

- **Tratamiento de Datos Faltantes:**
  - Imputación de variables numéricas mediante la **mediana** (SimpleImputer con strategy='median').
  - Imputación de variables categóricas asignando la categoría constante 'Unknown' (SimpleImputer con strategy='constant').
  - Imputación específica en children y adults reemplazando valores nulos con 0.
- **Feature Engineering:**
  - has_agent / has_company: Flags binarias (1/0) que indican presencia de agente o compañía.
  - room_mismatch: Variable binaria que identifica si el tipo de habitación asignada difiere del tipo reservado (reserved_room_type $\neq$ assigned_room_type).
  - total_stay: Suma de noches en días de semana y fines de semana (stays_in_weekend_nights + stays_in_week_nights).
  - total_guests: Suma total de huéspedes (adults + children + babies).
  - is_alone: Variable binaria indicadora de si la reserva es de un único huésped (total_guests == 1).
  - cancellation_rate: Proporción histórica de cancelaciones del cliente calculada como $\frac{\text{previous_cancellations}}{\text{previous_cancellations}+\text{previous_bookings_not_canceled}+1}$.
- **Transformaciones de Datos:**
  - **Encoding:** Aplicación de **One-Hot Encoding** (OneHotEncoder con handle_unknown='ignore') sobre las variables categóricas.

3.2. Modelos Entrenados

3.2.1. Modelos Individuales: Árbol de Decisión, Random Forest y XGBoost

1. Árbol de Decisión

- **Hiperparámetros Optimizados y Validación:**
  - **Estrategia de CV:** Validación cruzada de 5 pliegues (StratifiedKFold, 5-Fold CV, random_state=42).
  - **Hiperparámetros:** max_depth=12, min_samples_split=10, class_weight='balanced', random_state=123.
- **Métrica Elegida para Optimización: F1-Score Macro**.
- **Estructura y Reglas Principales del Árbol:**
  - **Nodo Raíz (Nivel 0):** deposit_type_Non Refund $\leq$ 0,5. Las reservas con depósito no reembolsable se clasifican directamente hacia **Canceló**.
  - **Nivel 1 (Discrepancia de Habitación):** Para el resto de los casos, la regla evalúa room_mismatch $\leq$ 0,5. Al haber cambio de habitación asignada, baja drásticamente la probabilidad de cancelación.

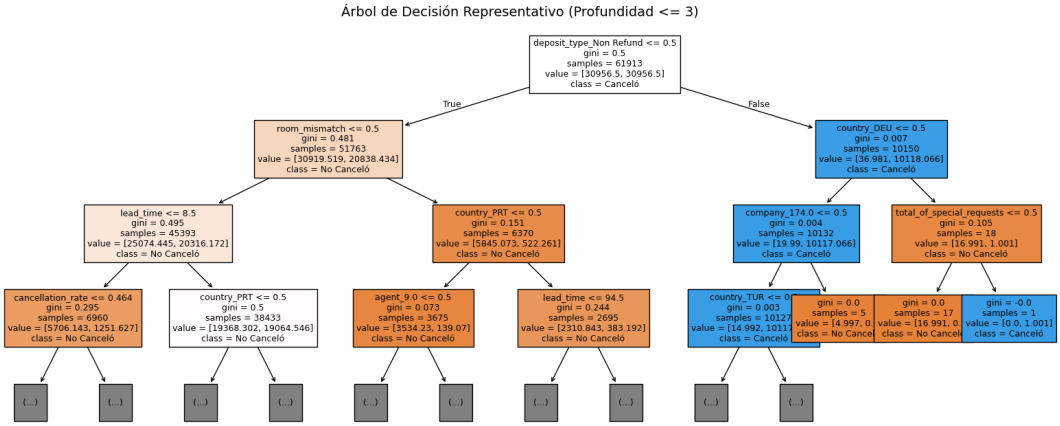


Figura 15: Estructura representativa del Árbol de Decisión (primeros 3 niveles de profundidad).

- **Niveles 2 y 3 (Anticipación, Geografía y Cancelaciones):** Evaluaciones sobre días de anticipación (lead_time $\leq$ 8,5), origen (country_PRT $\leq$ 0,5) y tasa previa de cancelación (cancellation_rate $\leq$ 0,464).

- **Importancia de Atributos (Top 10):**

  1. deposit_type_Non Refund: 0,316 (31,6 %)
  2. market_segment_Online TA: 0,122 (12,2 %)
  3. room_mismatch: 0,079 (7,9 %)
  4. lead_time: 0,078 (7,8 %)
  5. country_PRT: 0,068 (6,8 %)
  6. total_of_special_requests: 0,068 (6,8 %)
  7. required_car_parking_spaces: 0,051 (5,1 %)
  8. agent_240.0: 0,038 (3,8 %)
  9. cancellation_rate: 0,026 (2,6 %)
  10. arrival_date_year: 0,020 (2,0 %)

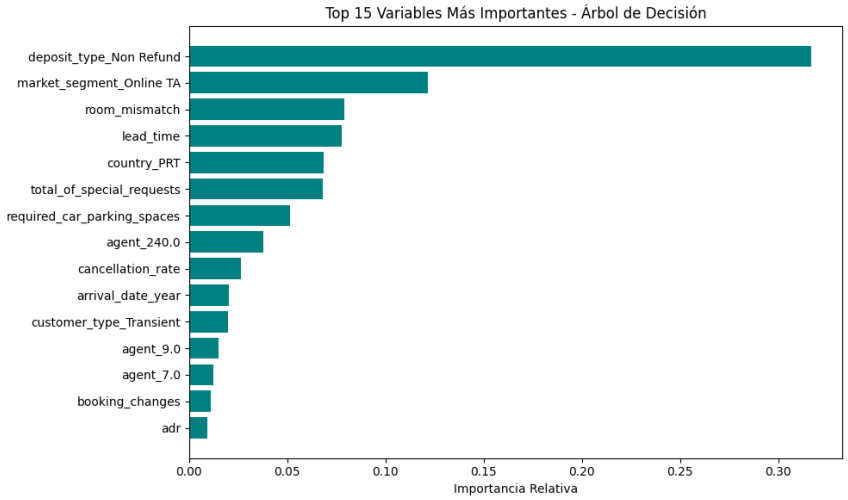


Figura 16: Top 15 variables más importantes en el Árbol de Decisión.

- **Evaluación en Entrenamiento, Validación y Matrices de Confusión:**
  - **Métricas en Entrenamiento (Train):** Accuracy: 0,85593, Precision Macro: 0,85744, Recall Macro: 0,85594, F1-Score Macro: 0,85578.

$$\text{Matriz de Confusión (Train):} \begin{pmatrix} \text{TN} = 25\,503 & \text{FP} = 5\,469 \\ \text{FN} = 3\,451 & \text{TP} = 27\,490 \end{pmatrix}$$

  - **Métricas en Validación (5-Fold CV):** Accuracy: 0,84530, Precision Macro: 0,84746, Recall Macro: 0,84532, F1-Score Macro: 0,84506.

$$\text{Matriz de Confusión (Validación):} \begin{pmatrix} \text{TN} = 24\,961 & \text{FP} = 6\,011 \\ \text{FN} = 3\,567 & \text{TP} = 27\,374 \end{pmatrix}$$

2. Random Forest

- **Hiperparámetros Optimizados y Validación:**
  - **Estrategia de CV:** Validación cruzada de 5 pliegues (StratifiedKFold, 5-Fold CV, random_state=42).
  - **Hiperparámetros:** n_estimators=300, max_depth=100, min_samples_split=4, class_weight='balanced', random_state=123.
- **Métrica Elegida para Optimización: F1-Score Macro**.
- **Estructura y Reglas Principales (Árbol #0 del Ensamble):**
  - **Nodo Raíz (Nivel 0):** assigned_room_type_A $\leq$ 0,5. La decisión primaria se basa en si la habitación asignada es de tipo 'A'.
  - **Rama Izquierda (assigned_room_type_A = 0):** Evalúa deposit_type_No Deposit $\leq$ 0,5, abriendo caminos hacia el país de origen (country_PRT $\leq$ 0,5) o la categoría de habitación reservada (reserved_room_type_F $\leq$ 0,5).
  - **Rama Derecha (assigned_room_type_A = 1):** Divide según si el canal de distribución fue directo (distribution_channel_Direct $\leq$ 0,5), combinando con el tipo de habitación reservada y noches en fin de semana (stays_in_weekend_nights $\leq$ 3,5).

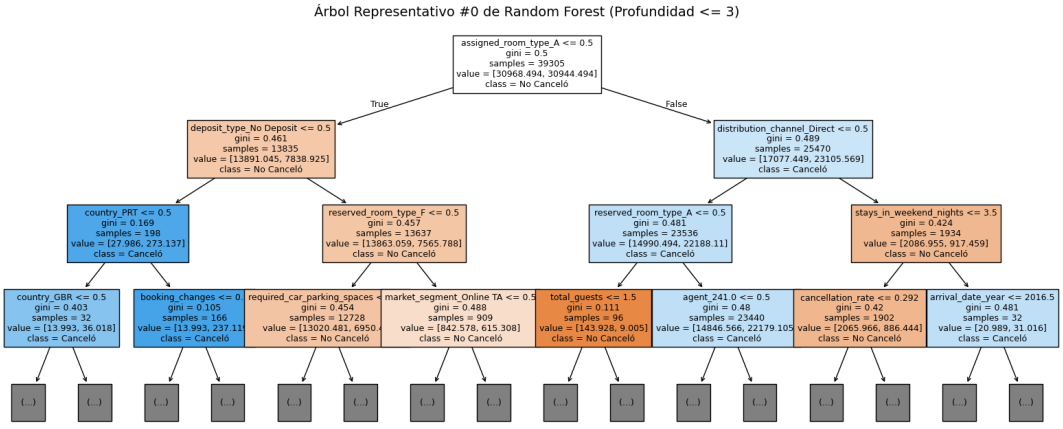


Figura 17: Estructura representativa del Árbol #0 de Random Forest (profundidad $\leq$ 3).

- **Importancia de Atributos (Top 10):**
  1. lead_time: 0,083 (8,3 %)

2. country_PRT: 0,070 (7,0 %)
3. total_of_special_requests: 0,050 (5,0 %)
4. deposit_type_No Deposit: 0,050 (5,0 %)
5. adr: 0,049 (4,9 %)
6. deposit_type_Non Refund: 0,043 (4,3 %)
7. arrival_date_day_of_month: 0,036 (3,6 %)
8. arrival_date_week_number: 0,035 (3,5 %)
9. total_stay: 0,027 (2,7 %)
10. room_mismatch: 0,026 (2,6 %)

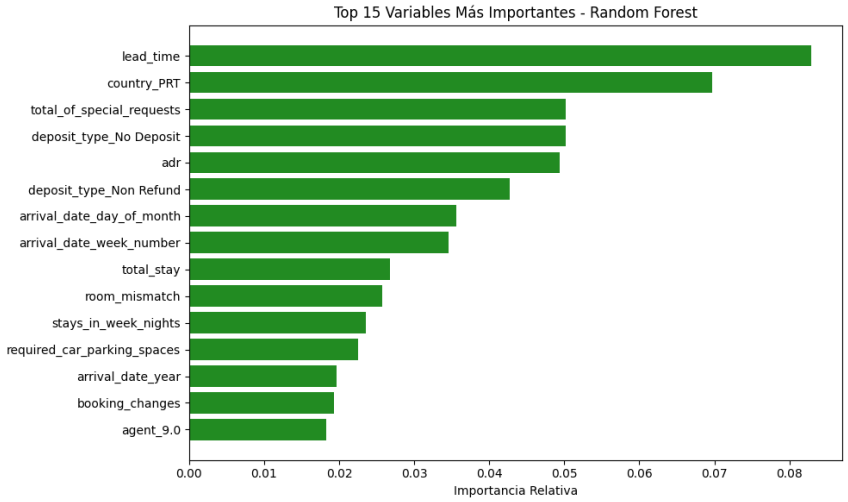


Figura 18: Top 15 variables más importantes en Random Forest.

- **Evaluación en Entrenamiento, Validación y Matrices de Confusión:**
  - **Métricas en Entrenamiento (Train):** Accuracy: 0,98907, Precision Macro: 0,98907, Recall Macro: 0,98906, F1-Score Macro: 0,98907.

$$\text{Matriz de Confusión (Train):} \begin{pmatrix} \text{TN} = 30\,673 & \text{FP} = 299 \\ \text{FN} = 378 & \text{TP} = 30\,563 \end{pmatrix}$$

  - **Métricas en Validación (5-Fold CV):** Accuracy: 0,88196, Precision Macro: 0,88217, Recall Macro: 0,88196, F1-Score Macro: 0,88195.

$$\text{Matriz de Confusión (Validación):} \begin{pmatrix} \text{TN} = 27\,676 & \text{FP} = 3\,296 \\ \text{FN} = 4\,012 & \text{TP} = 26\,929 \end{pmatrix}$$

3. XGBoost

- **Hiperparámetros Optimizados y Validación:**
  - **Estrategia de CV:** Validación cruzada de 5 pliegues (StratifiedKFold, 5-Fold CV, random_state=42).
  - **Hiperparámetros:** n_estimators=350, learning_rate=0.08, max_depth=7, subsample=0.8, colsample_bytree=0.8, gamma=1.0 (poda de nodos por ganancia), reg_alpha=0.1 (Lasso L_1), reg_lambda=1.5 (Ridge L_2).
- **Métrica Elegida para Optimización: F1-Score Macro**.

- **Estructura y Reglas Principales (Árbol #0 del Ensamble XGBoost):**
  - **Nodo Raíz (Nivel 0):** Evalúa el tipo de depósito (deposit_type_No Deposit), separando las reservas con política de depósito sin reembolso/estándar.
  - **Primeras Ramificaciones:** Incorpora decisiones secuenciales basadas en el tiempo de anticipación (lead_time < 9), la tasa histórica de cancelación (cancellation_rate $\leq 0{,}25$), la procedencia (country_PRT) y el espacio de estacionamiento requerido (required_car_parking_spaces).

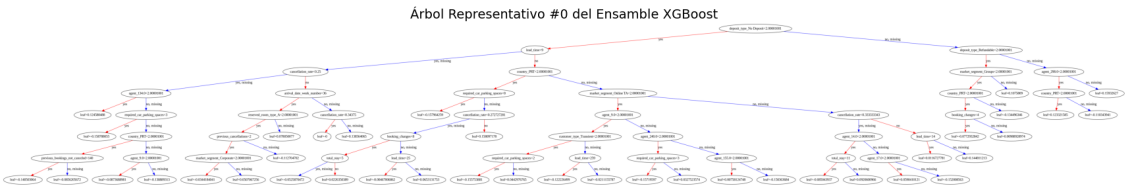


Figura 19: Estructura representativa del Árbol #0 del ensamble XGBoost.

- **Importancia de Atributos (Top 10):**
  1. deposit_type_Non Refund: 0,279 (27,9 %)
  2. deposit_type_No Deposit: 0,128 (12,8 %)
  3. market_segment_Online TA: 0,066 (6,6 %)
  4. room_mismatch: 0,039 (3,9 %)
  5. required_car_parking_spaces: 0,035 (3,5 %)
  6. cancellation_rate: 0,017 (1,7 %)
  7. agent_240.0: 0,016 (1,6 %)
  8. deposit_type_Refundable: 0,015 (1,5 %)
  9. country_PRT: 0,015 (1,5 %)
  10. agent_9.0: 0,014 (1,4 %)

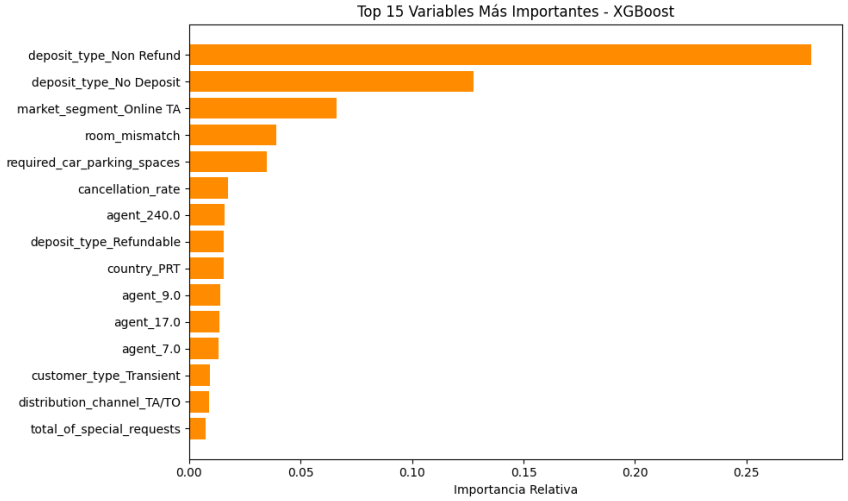


Figura 20: Top 15 variables más importantes en XGBoost.

- **Evaluación en Entrenamiento, Validación y Matrices de Confusión:**

- **Métricas en Entrenamiento (Train):** Accuracy: 0,90262, Precision Macro: 0,90273, Recall Macro: 0,90263, F1-Score Macro: 0,90262.

$$\text{Matriz de Confusión (Train):} \begin{pmatrix} \text{TN} = 27\,701 & \text{FP} = 3\,271 \\ \text{FN} = 2\,758 & \text{TP} = 28\,183 \end{pmatrix}$$

- **Métricas en Validación (5-Fold CV):** Accuracy: 0,87835, Precision Macro: 0,87842, Recall Macro: 0,87835, F1-Score Macro: 0,87834.

$$\text{Matriz de Confusión (Validación):} \begin{pmatrix} \text{TN} = 26\,983 & \text{FP} = 3\,989 \\ \text{FN} = 3\,543 & \text{TP} = 27\,398 \end{pmatrix}$$

3.2.2. Ensambles Híbridos

1. Ensamble Voting (Soft Voting: Random Forest + XGBoost)

- **Descripción del Ensamble y Modelos Base:** Se diseñó un **Voting Classifier** de votación blanda (voting='soft'), el cual promedia las probabilidades predichas por los dos clasificadores individuales de mejor desempeño: **Random Forest** ($W_{RF} = 1$) y **XGBoost** ($W_{XGB} = 1$). Al combinar las predicciones de una técnica basada en *bagging* y otra en *boosting*, se logra reducir la varianza individual de cada modelo.
- **Evaluación en Entrenamiento, Validación y Matrices de Confusión:**
  - **Métricas en Entrenamiento (Train):** Accuracy: 0,95112, Precision Macro: 0,95115, Recall Macro: 0,95113, F1-Score Macro: 0,95112.
  - **Métricas en Validación (5-Fold CV):** Accuracy: 0,88481, Precision Macro: 0,88481, Recall Macro: 0,88481, F1-Score Macro: 0,88481.

$$\text{Matriz de Confusión (Validación 5-Fold CV):} \begin{pmatrix} \text{TN} = 27\,433 & \text{FP} = 3\,539 \\ \text{FN} = 3\,593 & \text{TP} = 27\,348 \end{pmatrix}$$

2. Ensamble Stacking (Random Forest + XGBoost con Meta-Modelo Logístico)

- **Descripción del Ensamble y Meta-Modelo:** Se implementó un **StackingClassifier** que utiliza como modelos a **Random Forest** y **XGBoost**, utilizando sus probabilidades de predicción (stack_method='predict_proba') evaluadas mediante validación cruzada interna de 5 pliegues (cv=5). Como meta-estimador se empleó una **Regresión Logística** (LogisticRegression con C=1.0, class_weight='balanced', max_iter=1000).
- **Evaluación en Entrenamiento, Validación y Matrices de Confusión:**
  - **Métricas en Entrenamiento (Train):** Accuracy: 0,96574, Precision Macro: 0,96575, Recall Macro: 0,96574, F1-Score Macro: 0,96574.

$$\text{Matriz de Confusión (Train):} \begin{pmatrix} \text{TN} = 29\,837 & \text{FP} = 1\,135 \\ \text{FN} = 986 & \text{TP} = 29\,955 \end{pmatrix}$$

  - **Métricas en Validación (5-Fold CV):** Accuracy: 0,88547, Precision Macro: 0,88547, Recall Macro: 0,88547, F1-Score Macro: 0,88547.

$$\text{Matriz de Confusión (Validación 5-Fold CV):} \begin{pmatrix} \text{TN} = 27\,449 & \text{FP} = 3\,523 \\ \text{FN} = 3\,568 & \text{TP} = 27\,373 \end{pmatrix}$$

3.3. Cuadro Comparativo de Resultados

3.3.1. Tabla de Métricas en Validación / Test

Modelo	Accuracy	Precision	Recall	F1-Score	Configuración / Hiperparámetros
Árbol de Decisión	0.8453	0.8475	0.8453	0.8451	max_depth: 12, min_samples_split: 10, class_weight: 'balanced'
Random Forest	0.8820	0.8822	0.8820	0.8820	n_estimators: 300, max_depth: 100, min_samples_split: 4
XGBoost	0.8784	0.8784	0.8784	0.8783	n_estimators: 350, lr: 0.08, max_depth: 7, gamma: 1.0, reg_alpha: 0.1, reg_lambda: 1.5
Ensamble Voting	0.8848	0.8848	0.8848	0.8848	Soft Voting: RF (w=1) + XGB (w=1)
Ensamble Stacking	0.8855	0.8855	0.8855	0.8855	Stacking: RF + XGB, Regresión Logística

Cuadro 7: Comparativa de performance de los mejores modelos sobre el set de validación / prueba.

3.3.2. Análisis de Desempeño y Preguntas de Discusión

- **Análisis Train vs. Test (Overfitting / Underfitting):**
  - **Árbol de Decisión:** F1-Score Train 0,8558 vs Validación 0,8451. La poda por profundidad (max_depth=12) limitó adecuadamente el sobreajuste.
  - **Random Forest:** F1-Score Train 0,9891 vs Validación 0,8820. Exhibe varianza respecto al set de entrenamiento por su alta profundidad (max_depth=100), pero el promediado de árboles en el ensamble preservó un rendimiento muy competitivo en validación.
  - **XGBoost:** F1-Score Train 0,9026 vs Validación 0,8783. Logró la mayor estabilidad y control del sobreajuste ($\Delta \approx 2{,}4\,\%$), favorecido por sus términos de regularización L_1, L_2 y la poda por ganancia mínimo (γ).
  - **Ensamble Voting (RF + XGB):** F1-Score Train 0,9511 vs Validación 0,8848. Suavizó las diferencias individuales y superó la métrica de ambos clasificadores por separado.
  - **Ensamble Stacking (RF + XGB → Regresión Logística):** F1-Score Train 0,9657 vs Validación 0,8855. El meta-modelo ajustó las fronteras de decisión de forma no lineal sobre las probabilidades producidas en validación cruzada, alcanzando la métrica más alta del estudio sin incrementar el sobreajuste desmedidamente en validación.
- **Modelo con Mejor Desempeño:** El Ensamble Stacking (RF + XGBoost con Meta-Modelo Logístico) obtuvo la mejor performance global en validación cruzada ($F1$-Score = 0,88547), seguido muy de cerca por el Voting Classifier (0,88481). Ambas arquitecturas híbridas demostraron el beneficio directo de combinar bagging y boosting.
- **Variables Más Relevantes:** En los modelos base destacaron consistentemente la política de depósitos (deposit_type_Non Refund y deposit_type_No Deposit), el tiempo de anticipación de la reserva (lead_time), el país de origen (country_PRT), el segmento de mercado (Online TA), el indicador de cambio de habitación (room_mismatch) y la tasa histórica de cancelaciones (cancellation_rate).
- **Impacto del Preprocesamiento e Ingeniería de Características:** Las transformaciones con mayor impacto positivo en la capacidad predictiva de los modelos fueron la creación de la tasa histórica de cancelación del cliente (cancellation_rate), la flag que indica que la habitación reservada fue distinta a la asignada (room_mismatch) y la unificación de canales/países mediante One-Hot Encoding.
- **Experimentos Fallidos y Aprendizajes:** La inclusión de modelos lineales individuales o árboles de decisión sin regularizar/podar derivó en un sobreajuste severo o baja capacidad predictiva. Además, intentar utilizar *Hard Voting* redujo la precisión comparado con *Soft Voting* o Stacking.
- **Líneas Futuras de Trabajo:**
  - **Optimización de hiperparámetros:** Resultó costoso probar diversas combinaciones de hiperparámetros debido al elevado tiempo de cómputo que implica entrenar los modelos de forma reiterada.

- **Probar diferentes ensambles:** Se evaluó un número reducido de combinaciones entre modelos base y meta-estimadores, por lo que queda pendiente explorar nuevas arquitecturas de ensamble.
- **Explorar combinatorias de variables:** Probar con distintas combinaciones del conjunto de variables para identificar si algunas generan ruido que interfiera con el entrenamiento, lo cual también presentó un alto requerimiento de tiempo de procesamiento.

3.3.3. Entregas Realizadas en Kaggle

Cuadro 8: Resultados de las principales entregas en la plataforma Kaggle.

Modelo / Experimento	**Public Score Kaggle**
Árbol de Decisión	0.84456
Random Forest	0.88263
XGBoost	0.87660
Ensamble Voting	0.88354
Ensamble Stacking	0.88430